

SKKU HEALTHCARE AGENTIC AI CHALLENGE 2026

Interactive Clinical Trial Recommendation

멀티 에이전트 시스템: 근거 기반 임상시험 매칭 및 추천

[팀명] / 2026

임상시험 참여조건 매칭이 왜 어려운가

환자와 임상시험 사이의 정보 격차는 세 가지 다른 층위에서 동시에 발생한다.

1. 조건 복잡성

포함/제외 기준 한 문장 안에 임상 스코어링과 진단 가이드라인이 그대로 묶여 있다.

```
"Diagnosis of pancreatitis according to Atlanta guidelines, moderately severe or severe pancreatitis (APACHE score  $\geq$ 8 on admittance)"
```

- NCT06113419 포함기준, S001

2. 정보 부족

환자 정보는 한 줄짜리 vignette인데, 조건은 수치화된 검사 결과를 요구한다.

```
"29yo woman, palpitations, heat intolerance, weight loss, fine tremor, tachycardia, diffuse non-tender goiter"
```

이 한 문장만으로는 "Thyroid receptor antibody (TRAb) was positive" 같은 조건을 판정할 수 없다: 실제로 전체 10환자 데이터에서 373개 기준 중 218개(58%)가 UNKNOWN으로 남았다.

3. 근거 요구


판정에는 원문 근거가 함께 있어야 신뢰할 수 있다. 근거가 없으면 추측 대신 정직하게 모른다고 답해야 한다.

```
evidence: null  
reasoning: "No imaging results"
```

- NCT06113419 포함기준(영상 소견), S001, verdict UNKNOWN

에이전트 구성도: 7개 역할 파이프라인

각 박스는 독립된 system prompt를 가진 개별 Groq 호출이며, 결과는 디스크에 캐시되어 재실행 비용은 \$0이다.



환각을 품까지 보내지 않는다

두 가지 원칙을 서버 쪽에서 강제한다: 근거 문자열 일치, 그리고 성급한 확정 판정 금지.

근거 인용은 서버가 강제한다


`assert_traces.py`는 `extraction[].evidence_quote`가 환자 원문(patient_text)의 완전한 부분 문자열인지를 하드 어서션으로 검사한다. 하나라도 위반하면 전체 검증이 실패(exit code 1)한다.

판정 스키마도 자유 텍스트가 아니라 고정된 4값 열거형(MET / NOT_MET / UNCERTAIN / UNKNOWN)으로 제한된다.


결과: vignette에 없는 사실(예: 언급 없는 TRAb 양성)은 검증을 통과할 수 없고, 통과하지 못한 결과는 화면/폼에 도달하지 않는다.

불확실성 보존: ELIGIBLE은 40건 중 1건뿐

10환자 × 4시험 = 40건의 시험 단위 판정에서 **ELIGIBLE**은 1건(2.5%)에 그쳤다: 정보가 부족하면 확정하지 않는다는 원칙이 수치로 드러난다.



기준(criterion) 단위 373건 판정:



S002 (29세, Graves 의심): 근거로 제외 판정

나이 하나만으로도 오판을 막는다: 시스템이 원문 조건 문자열을 직접 대조해 근거와 함께 제시한 사례.

환자 S002

"29yo woman, palpitations, heat intolerance, weight loss, fine tremor, tachycardia, diffuse non-tender goiter"

추출 필드: age=29 (근거 "29yo"), sex=female (근거 "woman")

NCT06392906

Orbital Radiotherapy in Grave's Ophthalmopathy 1 Week vs 2 Weeks (OraGO-1 Trial)

Phase 3 / 포함기준

"Non-pregnant adults (aged 35 years or older)"

NOT_MET 근거: "age: 29": 사유: "Age under 35"

시험 단위 결과: eligibility = **INELIGIBLE** (4개 후보 중 순위 4위)

rationale: "Patient age does not meet inclusion criteria"

→ 사람이 그대로 재확인 가능한 감사 추적: 조건 원문, 판정, 근거, 사유가 한 줄에 함께 남는다.

질문 → 가상 답변 → 판정 변화

부족한 정보를 되물어 채운 뒤, 영향을 받는 기준만 다시 매칭한다.

메커니즘 (pipeline.py, 이미 구현됨)

- 1. **reeval-record-answer-generator**: 진단과 부합하는 가상의 확장 기록(extended_record)과, 각 확인질문에 대한 답변을 생성한다. 답변의 evidence_quote는 새로 만든 extended_record의 완전한 부분 문자열이어야 한다: 근거 검증을 재귀적으로 다시 적용.
- 2. **reeval-targeted-rematcher**: 답변이 실제로 영향을 주는 기준만 골라 재매칭하고, verdict_changes: [{nct_id, criterion, before, after}] 형태로 변화를 기록한다.

실측 결과 (traces.json, 2026-07-08 실행)

환자 10명 전원에서 재평가 루프가 실행되어 총 **88건의 판정 변화**가 발생했다. 대표 사례 (S001, 급성 췌장염 의심):

nct_id	criterion	before → after
NCT06113419	Biliary pancreatitis diagnosed on imaging (ultrasound, MRI, and/or CT)	UNKNOWN → NOT_MET

확장 기록의 영상 소견(담석·담관 확장 없음)이 답변으로 반영되자, 정보 부족(UNKNOWN)이던 기준이 근거 있는 NOT_MET으로 확정되었다.

평가 축 (30% 배점): 매칭 정확도 72.5%

블라인드로 작성된 정답 라벨 40건과 비교해 측정했다 (독립 라벨러 2명, 일치율 95%).

측정 방법 (eval.py, 이미 작성됨)

재평가 이전(pre-reeval) matcher 판정을 eval_labels.json과 비교한다. 라벨은 **매칭 결과를 보지 않고** 조건 원문 + 환자 vignette만 읽어 6명 이상 환자에 걸쳐 약 40개 (환자, 시험, 기준) 행을 사람이 직접 작성한다: 순환 검증(matcher가 자기 자신을 채점)을 피하기 위함.

출력: 정확도(accuracy), 판정별 혼동행렬(confusion matrix), 그리고 혼동행렬 숫자에서 직접 계산한 오류 분석(가장 약한 판정 클래스, UNKNOWN→확정판정 오분류 건수).

결과 (eval_results.json, 2026-07-08)

정확도 72.5% (29/40 일치, 텍스트 미매칭 0건). 라벨은 매칭 결과를 보지 않은 독립 라벨러 2명이 작성했고(일치 38/40 = 95%), 불일치 2건은 제3의 심판이 조정했다.

가장 약한 클래스: NOT_MET (재현율 20%). 가장 중요한 실패 유형: 정답이 UNKNOWN인데 확정 판정을 내린 **4건**, 즉 근거 없는 확신의 제조다. 나머지 오류 7건은 UNCERTAIN 경계 판정으로, 상대적으로 저위험 오류다.

보수성 트레이드오프, 이제 정량으로

정답 라벨 40건 중 **27건(67.5%)이 UNKNOWN**: 짧은 vignette 특성상 절반 이상은 원문이 침묵한다. 시스템은 이 27건 중 22건을 올바르게 UNKNOWN으로 유지했다(재현율 81%). 과잉확신 방지라는 설계 목표는 지켜졌고, 다음 개선 대상은 NOT_MET 감지력이다.

라이브 데모

직접 실행해볼 수 있습니다

전체 파이프라인은 표준 라이브러리 + Groq 무료 티어만으로 동작하며, 재실행 비용은 \$0이다.

데모 링크

<https://keonheek.github.io/clinical-trial-agent-demo/>

저장소

<https://github.com/keonheek/clinical-trial-agent-demo>

재현 방법 (1줄)

```
python3 fetch_trials.py && python3 pipeline.py && python3 assert_traces.py
```

GROQ_API_KEY 환경변수 필요 (.env). 모든 LLM 호출은 cache/에 디스크 캐시되어 재실행은 \$0.

사용 데이터와 책임 범위

데이터 출처

- **ClinicalTrials.gov**(미국 NLM/NIH): 시험 레코드, 제목, phase, 참여조건 원문은 미국 정부 저작물로 공개 도메인. 현재 모집 중인 실제 시험 16건을 API v2로 직접 조회했다(가상 데이터 아님).
- **환자 vignette**(S001/S002/S008): 과제 브리핑에 공개된 예시 환자를 그대로 인용한 가상 데이터이며, 실제 환자 정보가 아니다.
- **Groq**(무료 티어, llama-3.3-70b-versatile): 모든 에이전트 호출에 사용. 유료 Anthropic API는 어디에도 사용하지 않았다.

의학적 면책

출력 결과는 의학적 자문이 아닌 참고용입니다.

이 시스템은 해커톤 역량 시연(capability demo)이며 임상적으로 검증되지 않았다. 시험 참여 자격은 반드시 해당 시험의 연구팀과 자격을 갖춘 의료진을 통해 최종 확인해야 하며, 이 시스템의 판정만으로 등록 여부를 결정해서는 안 된다.

팀 구성 및 역할

아키텍처 · 파이프라인

건희

- pipeline.py 7-역할 오케스트레이션
- fetch_trials.py (ClinicalTrials.gov 연동)
- assert_traces.py 검증 스크립트

데이터 · 평가 라벨링

팀원

- eval_worksheet.json 블라인드 라벨링 → eval_labels.json
- patients_all10.json 확장 케이스 검토
- eval.py 실행 및 오류 분석 리뷰

발표 · 슬라이드

팀원

- 발표 스토리라인 및 시연 시나리오
- 라이브 데모 진행
- Q&A 대응