

SKKU HEALTHCARE AGENTIC AI CHALLENGE 2026

Interactive Clinical Trial Recommendation

불확실성을 진단하고 다음 행동을 고르는 멀티에이전트 임상시험 매칭·추천 시스템

백엔드 · 파이프라인

건희

프론트엔드 · 데모

정원

기획 · 평가(eval)

지우

임상시험 매칭이 어려운 진짜 이유

환자 기록은 불안전하고, 참여조건(criterion)은 원문이 길고 조건이 복잡하다. 이 정보 격차에서 기존 접근은 두 방향으로 실패한다.

실패 1 — 확신에 찬 오답 (false certainty)

부족한 정보를 근거 없이 메워, 기록이 침묵하는데도 MET/NOT_MET로 확정한다. 환자를 잘못 통과시키거나 잘못 탈락시키는 가장 위험한 실패.

```
criterion: "TRAb was positive"  
기록: 언급 없음 → 그럼에도 "MET" 확정 x
```

헬스케어에서 이 한 건이 harmful interaction이 된다.

실패 2 — 질문 폭탄 (question spam)

반대 방향의 실패: 모든 공백마다 사람에게 되묻는다. 질문이 많다고 좋은 상호작용이 아니다 — 실제로는 상호작용 비용만 키운다.

```
미해결 criterion 다수  
→ 공백마다 전부 질문? x
```

주최 브리핑의 "단일 질의응답형 제외" 기준이 겨누는 지점.

우리의 차별점, 한 문장

모든 불확실성에 **질문으로** 답하지 않는다.
불확실성의 원인을 진단하고, 가장 안전한 다음 행동을 고른다.

ASK · 되묻기

RETRIEVE · 조회

VERIFY · 확인


ESCALATE · 이관

STOP · 중단

평가 관점: 정확도(accuracy)만이 아니라 **harmful interaction rate**(잘못 통과·근거 없는 확신)를 앞세운다. 이후 모든 슬라이드가 이 문장으로 연결된다.

주최 예시 6단계는 전부 포함 — 우리가 더한 세 계층

NIH TrialGPT(Nature Communications, 2024) 구조에 독립적으로 수렴 — Retrieval → Matching(criterion별 verdict+설명) → Ranking. 행동 선택 계층(action_policy)이 흐름을 분기시킨다(질문 / 진행).



주최 예시의 6단계(정보 추출 → 기준 파싱 → 매칭 → 갭 탐지 → 질문 생성 → 추천)는 전부 그대로 있다. 우리가 더한 세 계층 = ① action_policy 진단 → 행동 게이트 · ② verdict(모델) / effect(코드) 분리 · ③ 커버리지 · 중재목적 · 우선순위 계층.

다음 단계

① action_policy → 실제 오케스트레이터: 행동별 개별 실행 (RETRIEVE/VERIFY/ESCALATE)

구현 2026-08-16

② 추천 순위에 임상 적합성 반영: 중재목적·Phase 부담·커버리지를 순위 키에 (다음 장)

다음 단계

③ 근거 recency: lab·영상 유효기간 → 만료 시 재검

추천 우선순위는 이렇게 정해진다

주최 07-23 기준: "가장 적절한" 순서는 적격성만이 아니라 **임상적 적합성**(Phase·중재 목적·환자 부담)까지 본다. 실제로 실행되는 정렬 키를 그대로 공개한다 — `ranking.py`, RANKING_VERSION 2026-08-16.

실행되는 정렬 키 (위 단계가 항상 우선)

- 0 **적격성 클래스** — 적격 > 미확정 > 부적격
- 1 **차단 기준 수** — hard FAIL이 적은 순
- 2 **중재 목적** — 치료 > 지지 > 관리 > 관찰 (확신 낮으면 관찰과 등급)
- 3 **Phase 부담** — 4 > 3 > 2 > 1, NA는 중간
- 4 **원문 커버리지** — 50% 미만이면 감점
- 5 **미해결 비율** — (미해결/파싱 수) → 미해결 수 → NCT

모든 단계가 **시험 레코드의 사실이거나 코드가 센 값**이다 — 모델 의견은 한 칸도 들어가지 않는다. 각 시험 카드에 `rank_reason` 한 줄로 근거가 표시된다.

왜 이 순서인가 (설계 근거)

같은 적격성 클래스라면 **환자에게 치료 기회가 되는 시험을 먼저 검토한다**. 그리고 **확신 없는 분류는 순위를 올리 지 않는다** — 추정 라벨이 실제 치료 시험을 밀어내면 안 되므로, 저확신 분류는 관찰 연구와 같은 칸으로 내린다.

24/40

순위가 실제로 이동

5/10

1위 시험이 바뀐 환자

2칸

최대 이동 폭

10/10

hard exclusion 유지

전 → 후 (S002, Graves')

이전 1위 NCT06963203 — **관찰 연구(추정) · Phase NA**

현재 1위 NCT05461820 — **치료 목적 · Phase 4**

`eval.py`는 `rank`를 읽지 않는다 — 블라인드 라벨과 짝지어진 **정확도 82.5%(n=40)**는 **불변**이며, 골든 순서는 `expected_ranking.json`으로 CI에서 고정된다.

의도적으로 넣지 않은 것 — '환자 부담'은 지금 **Phase 프록시만** 쓴다. 방문 횟수·이동 거리·시험 기간 데이터가 레코드에 없기 때문이다. 향후 `trial_design` 사이드카로 분리해 붙인다.

직접 실행되는 상호작용 데모

sdic-trial-demo.vercel.app — 사람이 답을 주면 영향받은 criterion만 실시간 재평가되고 순위가 바뀐다.

시연 시나리오 (고정)

- 1. 환자 선택 → 후보 임상시험 추천 목록 + 각 시험의 판정·근거, 그리고 순위 근거 한 줄(rank_reason) 표시
- 2. '왜 이 질문인가' 카드 — 아래 세 값이 배포 화면에 표시되고, 질문은 영향 큰 순서로 정렬되어 온다
- 3. 답변 입력 → 영향받은 criterion만 실시간 재평가 → 순위 변화 확인

affects_trials

이 답 하나가 몇 개 시험에 영향을 주는가

affects_criteria

몇 개 조건(criterion)을 풀어주는가

may_change_rank

추천 순위를 바꿀 수 있는가

왜 라이브인가

정적 화면이 아니라 불확실성 → 질문 → 재평가의 실제 루프를 보여준다. 이것이 "단일 질의응답형"과 갈리는 지점.

세 값은 action_policy.enrich_questions가 트레이스에서 결정론적으로 계산해 API가 서빙한다 — 프론트가 지어내는 숫자가 아니다.

백업 (리허설 필수)

네트워크 지연 대비: 사전 녹화 영상 + 정적 트레이스 뷰어를 준비. 데모 환자·질문 시나리오는 사전 고정한다.

verdict(판정)와 effect(효력)의 분리

우리가 발견한 버그에서 출발한 설계. "MET"이 매처에겐 '환자 통과', 라벨러에겐 '문장이 참'으로 읽혀 **exclusion criterion이 반전** 채점되고 있었다.

2계층으로 분리했다

계층	누가 결정	내용
verdict	모델(LLM)	이 문장이 환자에게 참인가 (MET/NOT_MET/UNCERTAIN/UNKNOWN)
effect	코드 테이블	그 판정이 적격성에 주는 효력 (PASS/FAIL/REVIEW)

exclusion + MET = FAIL은 코드가 결정한다 — 모델이 추론하지 않는다. 극성(polarity)을 거꾸로 얻을 수 없다.

반전 예시 (exclusion)

```
exclusion: "Active autoimmune disease"
verdict = MET (문장이 참: 있다)
```

순진한 해석: MET → "통과" ×
올바른 효력: 제외기준이 참 → **FAIL** (탈락)

격리된 전/후 효과 — MET 정의 충돌 수정 *단독*, 동일 데이터: **+5.0pp** (이 수정만의 효과. 현재 헤드 라인 아님)

문제를 '용어 정의 충돌'로 진단한 과정 자체가 설계 스토리다. 최종 정확도 82.5%는 이 수정 이후의 추가 개선을 포함한다.

불확실성 진단 → 행동 선택

"질문 수를 줄였다"가 아니라 "질문이 필요한 경우를 판별한다". 유형→행동 매핑은 코드가 결정한다(모델 아님).

불확실성 10종 → 행동 — action_policy.ACTION_TABLE 전문

불확실성 유형	선택 행동 (대체 행동)	불확실성 유형	선택 행동 (대체 행동)
MISSING 기록에 없음	ASK 되묻기 (RETRIEVE)	BOUNDARY 경계값	REQUEST_LATEST (ESCALATE)
STALE 값이 오래됨	REQUEST_LATEST 최신 검사 요청	CLINICAL_JUDGMENT 임상 판단	ESCALATE 전문가 이관
INSUFFICIENT_EVIDENCE 근거 부족	VERIFY 근거 확인	NOT_APPLICABLE 해당 없음	IGNORE — 질문 안 함
AMBIGUOUS 기준이 모호	PROTOCOL_REVIEW (ESCALATE)	CALCULABLE 계산 가능	CALCULATE 도구로 계산
CONFLICTING 기록끼리 충돌	ESCALATE 전문가 이관	DEFINITE_EXCLUSION 확정 제외	STOP — 질문 안 함

정직한 단서: 표는 완전히 구현돼 있지만 유형을 맞히는 정확도는 유형마다 다르다 — 스트레스셋에서 STALE 탐지는 0/3이었다(S11). 표의 매핑이 아니라 유형 인식이 아직 약한 지점이다.

게이트 (실측)

IGNORE·STOP은 gap 탐지 단계에서부터 질문으로 새지 않게 차단한다. 데모 10명 374개 기준: ASK 201 · STOP 86 · ESCALATE 11 · 이미 판정 76.

fail-safe

인식 못한 유형은 ESCALATE로 안전 실패 — 절대 조용히 통과시키지 않는다.

고정 어휘

유형은 자유 텍스트가 아니라 고정 열거형. 매치는 유형만 제안, 매핑은 코드.

근거 충분성 (evidence sufficiency)

같은 정보라도 근거의 격이 다르다. 추적 가능성(인용이 존재하는가)과 **충분성(그 인용이 결론을 지지하는가)**은 별개다.

세 축으로 근거를 평가한다

- **source_type** — symptom / lab / imaging / pathology / clinical_judgment ...
- **confirmation_level** — suspected / provisional / confirmed
- **directness** — direct / indirect

매처가 criterion별로 이 메타데이터를 함께 내면, `apply_evidence_sufficiency()`가 **양쪽 매칭 패스 모두**(1차 + 재평가)에서 과대 해석을 잡아 강등한다. pure module로 **구현·자체 테스트 완료**.

예시 — 의심 소견 ≠ 확진

```
criterion: "confirmed diagnosis 요구"  
근거: CT '의심(suspected)' 소견  
meta: imaging · suspected · indirect
```

MET (순진) → **UNCERTAIN + VERIFY**

'의심'이 '확진'을 대신할 수 없으므로 확신하지 않고 **VERIFY로 강등**한다. 코드로 검증되는 규칙이라 판정마다 일관된다.

다음 단계: 매처가 100% criterion에 메타데이터를 붙이도록 커버리지 확대.

정답지는 사람이, 블라인드로 작성했다

평가 무결성 원칙: 정답 라벨(expected verdict/action)은 사람이 **시스템 출력을 보지 않고** 조건 원문 + 환자 vignette만 읽어 작성했다.

maker ≠ checker

매처(maker)가 자기 출력을 채점(checker)하면 순환 검증이 된다. 그래서 라벨링과 판정을 **구조적으로 분리**했다.

보이는 라벨에 프롬프트를 맞추는 **label-fitting을 하지 않았다** — 점수를 올리는 법을 알지만 쓰지 않은 것이 신뢰의 핵심.

두 개의 평가셋

40

기본셋 라벨
(n=40, 블라인드)

51

스트레스셋 라벨
(n=51, 블라인드)

스트레스셋 = 5개 질환 × 7종 손상 변형(BASE + a~g). 교차 검수로 라벨 오류를 수정한 이력까지 공개 가능하다.

숫자로 보는 성능

82.5%

정확도 (n=40, 블라인드 라벨)

0

잘못 통과 (wrongly passed)
기본셋 5건 중 0 · 스트레스셋 2건 중 0

1 / 27

false certainty (침묵한 기준 중 확신 오류, 약 4%)

+5.0pp

MET 정의 수정 단독 효과 (동일 데이터, 헤드라인 아님)

안전성이 본론이다

탈락시켜야 할 criterion 5개 중: 3건 적중 + 2건 사람 리뷰 이관(REVIEW) → 잘못 통과 0건 (5건 중 0).
놓친 2건도 확정 통과가 아니라 REVIEW로 보냈다.

근거: eval_results.json — disqualifying recall 0.6, wrongly_passed 0, false_certainty 0.037

스트레스셋 — 정직한 스트레스 테스트 (n=51)

더 어려운 손상 변형에서: verdict 66.7% · action 66.7% · 불확실성 유형 적중 36.4%(n=22) · false certainty 41% — 그럼에도 잘못 통과는 여전히 0건 (탈락 대상 2건 중 0).

유형별로 정직하게: MISSING 6/9 · INSUFFICIENT_EVIDENCE 1/2 · CONFLICTING 1/3은 잡는다. STALE 0/3 · BOUNDARY 0/1 · CLINICAL_JUDGMENT 0/1 · AMBIGUOUS 0/3은 아직 못 잡는다.

fail-safe는 되문기를 놓치지 않게 한다 — 유형을 못 붙이면 매핑이 ESCALATE로 떨어져 사람에게 간다. 잘못 통과 0건은 별개 계층의 결과다 — 판정이 MET/NOT_MET이 아니면 effect가 REVIEW로 남고, exclusion+MET=FAIL을 EFFECT_TABLE이 강제하기 때문이다(S7). 유형 적중률과 잘못 통과는 서로 다른 계층에서 결정된다.

근거: stress_eval_results.json (n=51, 5질환×7손상변형, 블라인드)

하나의 hard exclusion은 평균으로 못 지운다

적격성(eligibility)은 점수 평균이 아니라 **위계 판정**이다 — `decide_eligibility`.

위계 판정 (평균 금지)

충족 조건이 아무리 많아도 **hard FAIL 하나면 탈락**. 24개 PASS + 1개 결정적 exclusion FAIL = **INELIGIBLE**.

PASS x24 + FAIL x1 → 전체 INELIGIBLE

평균이었다면 96% "적격"으로 오판했을 상황.

책임의 경계

- 추천 에이전트는 판정에도 순위에도 관여하지 않는다 — 근거 서술만 한다.
- 적격성 결정은 전부 **코드 도구**가 한다(maker≠checker) — `decide_eligibility`.
- 순위도 **코드가 정한다**(`ranking.py`) — 결정론적이고, `rank_reason`으로 근거가 화면에 노출된다.
- 부적격 확정 시험의 미해결 기준은 **질문하지 않고 STOP** — 무의미한 되묻기를 차단한다.

시스템은 근거를 갖춘 초안을 낼 뿐, 등록 결정을 대신하지 않는다 — 최종 판단은 연구팀·의료진의 몫이다.

우리가 아는 한계 — coverage blindness

순위가 '미해결 criterion 수'만 보던 동안, **parser가 원문을 적게 읽은 시험이 '더 확실해' 보였다**. 이 한계를 우리가 먼저 문서화했고(RECOMMENDATION-DEFINITION.md), 08-16에 순위 키를 고쳤다.

반증 사례 (정답지 baseline)

시험	파싱 criterion	미해결
T001 종양학, 원문 길다	4개만 뽑힘	1
T003 알츠하이머, 원문 짧다	2개로 거의 커버	0

이전 로직에서는 T003이 "더 확실"해 상위 추천됐다 — T001은 원문이 길어 덜 검토됐을 뿐인데도. 08-16 키는 데모셋에서 커버리지 50% 미만을 감점해 이 실패 유형을 막지만(4개 시험 발동), 스트레스셋 시험에는 아직 원문 추정치가 없어 **이 사례 자체는 남아 있다**.

순위 정의 A~D를 검토했고, 무엇을 채택했는지 밝힌다

- **A. 확인 부담 최소화** (구 기본값) — 위 반증 사례에 그대로 취약
- **B. 적격 가능성 우선** — 위험도(치명/사소) 반영 못함 → 미채택
- **C. 질환/중재 관련성** — 실측 결과 **변별력 있음**: 데모 40개 시험 = 관찰 28(저확신 19) · 치료 11 · 의료 전달 1 → **순위 키에 반영(2026-08-16)**
- **D. 커버리지 정규화** — 부분 채택: 미해결을 **비율**로 정규화 + 커버리지 50% 미만 **감점**

현재 상태: **원문 대비 커버리지 %는 데모 40개 시험 카드 전부에 표시된다**(구현·배포 완료, 스트레스셋은 미포함). Phase·중재목적은 표시만이 아니라 **순위 키 안에 들어가 있다**. 남은 한계 — 환자 부담은 아직 Phase 프록시뿐이다(방문·거리·기간 데이터 없음).

다음 단계 (로드맵)

'구현 vs 로드맵'을 나눠 제시하는 것 자체가 깊이의 신호다. 07-23 로드맵 중 두 항목은 이번에 구현으로 넘어갔다.

구현 완료 — 2026-08-16 (기존 로드맵 ②·③)

추천 순위에 임상 적합성 반영 — 중재 목적·Phase 부담을 순위 키에 넣었다. **커버리지 정규화(D안)**는 부분 채택 — 미해결을 비율로 정규화 + 커버리지 50% 미만 감점. `ranking.py` · 골든 순서는 `expected_ranking.json`으로 CI에 고정 · 정확도 82.5%(n=40)는 불변.

1

action_policy → 실제 오케스트레이터

진단·게이트를 넘어, 행동별 개별 실행 (RETRIEVE/CALCULATE/VERIFY/ESCALATE)과 에이전트 시퀀싱까지.

2

환자 부담의 실데이터화

지금은 Phase 프록시뿐. 방문 횟수·이동 거리·시험 기간을 `trial_design` 사이드카로 분리해 순위 키에 추가.

3

근거 recency / 유효기간

lab·영상 유효 윈도우를 두고 만료 시 재검(STALE→REQUEST_LATEST)을 자동화.

4

불확실성 유형 인식 강화 — 매핑 표는 완성됐지만 STALE·BOUNDARY·CLINICAL_JUDGMENT 인식이 약하다(S11). 유형별 판별 신호를 코드 규칙으로 보강.

5

harmful interaction rate 실측 프로토콜 + 스트레스셋 질환 축 확장 + 실제 EMR 연동 관점의 과제.

연구실 입장에서 "이 팀과 후속 연구를 하면 무엇을 하게 되는가"가 보이도록 구성했다.

핵심 3줄

1. 질문이 아니라 행동을 고른다

불확실성의 원인을 진단하고 가장 안전한 다음 행동을 선택한다.

2. 판정은 모델, 결정은 코드

verdict는 LLM, PASS/FAIL·적격성·추천 순위는 코드. maker ≠ checker.

3. 잘못 통과 0건

기본셋 탈락 대상 5건 중 0 · 스트레스셋 2건 중 0. 안전이 정확도보다 앞선다.

"모든 불확실성에 **질문으로 답하지 않는다** — 원인을 진단하고 안전한 행동을 고른다."

건희 백엔드·파이프라인 · 정원 프론트엔드·데모 · 지우 기획·평가 | 감사합니다.

사용 데이터와 책임 범위

데이터 출처 · 라이선스

- **ClinicalTrials.gov** (미국 NLM/NIH) — 시험 레코드·제목·phase·참여조건 원문은 **미국 정부 저작물**, 공개 도메인. 현재 모집 중인 실제 시험을 API v2로 직접 조회(가상 데이터 아님).
- **환자 vignette** — 과제 브리핑에 공개된 예시 환자를 그대로 인용한 **가상 데이터**, 실제 환자 정보 아님.
- **LLM 추론** — 파이프라인은 **특정 모델에 종속되지 않는다**(LLM_BACKEND 전환형). 현재 기본값은 챌린지 지원 크레딧의 Anthropic API(Haiku 4.5)이고 Sonnet 5·Opus 4.8·Groq·로컬 Ollama로 교체 가능하다. 판정 이후의 결정(effect·적격성·순위)은 전부 코드라 **모델을 바꿔도 안전 성질이 유지된다**(S17 Q4). 모든 호출은 모델별로 분리된 디스크 캐시.

의료 면책 고지

출력 결과는 의학적 자문이 아닌 참고용입니다.

본 시스템은 **역량 시연(capability demo)**이며 임상적으로 검증되지 않았다. 시험 참여 자격은 반드시 해당 시험의 **연구팀과 자격을 갖춘 의료진**을 통해 최종 확인해야 하며, 이 시스템의 판정만으로 등록 여부를 결정해서는 안 된다.

모든 슬라이드 하단에 동일 고지를 상시 표기한다.

예상 질문 대비

Q1 · 왜 LLM 판정을 그대로 안 쓰나

LLM은 극성·효력을 거꾸로 낼 수 있다. verdict(LLM)와 effect(코드)를 분리해 **exclusion+MET=FAIL**을 코드가 강제한다(S7).

Q2 · 라벨 40개로 충분한가

기본셋 n=40에 더해 **스트레스셋 n=51**(5질환×7손상변형, 블라인드). 라벨은 시스템 출력을 보지 않고 작성 (S10·S11).

Q3 · 실제 병원 적용 장벽

EMR 연동, 근거 recency 유효기간, 환자 부담 실데이터가 남은 과제(S14). 최종 판단은 시험 연구팀·의료진의 몫이다.

Q4 · 모델 선택과 비용 (모델 종속성)

파이프라인은 LLM_BACKEND로 갈아끼운다. 동일한 블라인드 스트레스 라벨(n=51)로 3개 모델을 재실행한 결과:

모델	verdict 정확도	잘못 통과
Opus 4.8	80.4%	0건
Sonnet 5	76.5%	0건
Haiku 4.5 (현재 기본값)	72.6%	0건

근거: model_bakeoff_full.json — 모델별 캐시를 분리한 **별도 재실행**이므로, S11의 커밋된 스트레스 결과(66.7%)를 대체하는 수치가 아니라 **모델 간 비교용**이다. 정확도는 모델에 따라 움직이지만 **잘못 통과 0건은 셋 다 유지** — 안전 성질이 모델이 아니라 코드 계층에 있기 때문이다.

Q5 · coverage가 낮은 상태의 ELIGIBLE 의미

원문의 13%만 읽고 낸 ELIGIBLE과 90%를 읽고 낸 ELIGIBLE은 신뢰도가 다르다. 그래서 **커버리지 %를 모든 시험 카드에 표시한다**(구현·배포 완료). 나아가 커버리지 50% 미만은 **순위에서 감점**된다(S5).

백업 자료

confusion matrix, 스트레스셋 구성표, 아키텍처 상세(agent_orchestration.html), traces 뷰어.